LAPORAN PRAKTIKUM

PRAKTIKUM PENAMBANGAN DATA

PERTEMUAN 5

FORECASTING



Disusun oleh:

Nama	:	Hanan Fijananto
NIM	:	24/538946/SV/24555
Kelas	:	A2
Dosen Pengampu	:	Dr.Imam Fahrurrozi, S.T., M.Cs.

PROGRAM STUDI D-IV TEKNOLOGI REKAYASA PERANGKAT LUNAK

DEPARTEMEN TEKNIK ELEKTRO DAN INFORMATIKA

SEKOLAH VOKASI

UNIVERSITAS GADJAH MADA

YOGYAKARTA

2026

A Tujuan

1. Mahasiswa dapat menerapkan metode forecasting berbasis machine learning, meliputi Neural Network, K-Nearest Neighbors (KNN), Decision Tree, Support Vector Regression (SVR), dan Random Forest, untuk memprediksi nilai periode berikutnya berdasarkan data historis

2. Mahasiswa dapat melakukan evaluasi performa model forecasting berbasis machine learning menggunakan metrik Root Mean Squared Error (RMSE) dan Pearson Correlation Coefficient

3. Mahasiswa dapat membandingkan performa model forecasting berbasis machine learning dan menentukan model terbaik berdasarkan hasil evaluasi

B Dasar Teori

B.1 Supervised Learning

Supervised learning merupakan pendekatan machine learning yang mempelajari hubungan antara variabel masukan (*input*) dan keluaran (*target*) berdasarkan data yang telah memiliki pasangan nilai masukan dan keluaran. Proses pembelajaran dilakukan dengan mengoptimalkan parameter model agar hasil prediksi mendekati nilai target yang sebenarnya. Pendekatan ini digunakan pada berbagai permasalahan prediksi, termasuk regresi dan klasifikasi [1]. Pada penelitian ini, supervised learning digunakan untuk mempelajari hubungan antara data historis harga saham dengan harga *Close* yang menjadi target prediksi.

B.2 Forecasting

Forecasting merupakan proses memprediksi nilai pada waktu yang akan datang berdasarkan informasi yang tersedia pada waktu sebelumnya. Dalam konteks *time*

series forecasting, data historis digunakan sebagai dasar untuk menghasilkan prediksi pada periode mendatang sehingga urutan waktu dan pola historis menjadi bagian penting dalam proses pemodelan [2]. Machine learning juga dapat diterapkan pada forecasting dengan membentuk hubungan antara observasi masa lalu sebagai fitur dan nilai masa depan sebagai target [3]. Pada penelitian ini, forecasting digunakan untuk memprediksi harga *Close* saham Tesla dua hari ke depan berdasarkan data historis tujuh hari sebelumnya.

B.3 Root Mean Squared Error (RMSE)

Root Mean Squared Error (RMSE) merupakan metrik yang digunakan untuk mengukur besarnya kesalahan antara nilai aktual dan nilai hasil prediksi. RMSE diperoleh dengan menghitung akar kuadrat dari rata-rata kuadrat selisih antara nilai aktual dan prediksi, yang dirumuskan sebagai berikut:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{1}$$

dengan y_i merupakan nilai aktual, $\hat{y}_i$ merupakan nilai prediksi, dan n merupakan jumlah data. RMSE memiliki satuan yang sama dengan variabel target dan memberikan penalti yang lebih besar terhadap kesalahan yang besar karena error dikuadratkan. Nilai RMSE yang semakin kecil menunjukkan kesalahan prediksi yang semakin rendah [4].

B.4 Pearson Correlation Coefficient

Pearson Correlation Coefficient merupakan ukuran statistik yang digunakan untuk mengetahui kekuatan dan arah hubungan linear antara dua variabel. Dalam evaluasi model prediksi, koefisien Pearson dapat digunakan untuk melihat sejauh mana pola nilai prediksi mengikuti pola nilai aktual. Nilainya berada pada rentang -1 hingga 1, dengan nilai mendekati 1 menunjukkan hubungan linear positif yang

kuat [5].

Persamaan Pearson Correlation Coefficient dapat dituliskan sebagai:

$$r = \frac{\sum_{i=1}^{n}(y_i - \bar{y})(\hat{y} * i - \overline{\hat{y}})}{\sqrt{\sum * i = 1^n (y_i - \bar{y})^2 \sum_{i=1}^{n}(\hat{y}_i - \overline{\hat{y}})^2}} \tag{2}$$

Dalam forecasting, Pearson tidak mengukur besar kesalahan prediksi secara langsung, sehingga penggunaannya sebaiknya dikombinasikan dengan metrik error seperti RMSE untuk memperoleh evaluasi performa model yang lebih lengkap [6].

C Hasil dan Pembahasan

C.1 Persiapan Lingkungan dan Import Library

Tahap pertama yang dilakukan adalah menyiapkan lingkungan kerja menggunakan Google Colab sebagai platform eksekusi, karena mendukung seluruh *library machine learning* yang diperlukan tanpa membebani perangkat lokal. Setelah lingkungan siap, seluruh *library* yang dibutuhkan untuk *preprocessing*, visualisasi, pemodelan, dan evaluasi diimpor sebagai berikut.

Listing 1: Install library

```
pip install xgboost
```

Setelah berhasil menginstall library xgboost, import beberapa library yang diperlukan.

```
import numpy as np
import pandas as pd
from math import sqrt
import matplotlib.pyplot as plt
from sklearn.ensemble import RandomForestRegressor
import math
from sklearn.metrics import mean_squared_error
from numpy import array
from sklearn.neural_network import MLPRegressor
from sklearn.neighbors import KNeighborsRegressor
from scipy.stats import pearsonr
from sklearn. tree import DecisionTreeRegressor
from sklearn.svm import SVC
from sklearn.svm import SVR
from xgboost import XGBClassifier

from sklearn import preprocessing
from sklearn.model_selection import train_test_split
from sklearn import metrics
from sklearn.metrics import mean_squared_log_error
from numpy import array
from scipy.stats import kurtosis, skew
```

Gambar 1: Output instalasi library xgboost

Library `pandas` dan `numpy` digunakan untuk membaca dan mengelola data, `matplotlib` digunakan untuk visualisasi, sedangkan `mean_squared_error` dan `pearsonr` digunakan sebagai metrik evaluasi model. Model *machine learning* yang digunakan meliputi `MLPRegressor` (Neural Network), `KNeighborsRegressor` (KNN), `DecisionTreeRegressor` (Decision Tree), dan `RandomForestRegressor` (Random Forest).

C.2 Import Dataset

Dataset yang digunakan pada praktikum ini adalah *Bike Sharing Dataset* (`https://www.kaggle.com/datasets/lakshmi25npathi/bikesharing-dataset`), yang berisi data peminjaman sepeda harian beserta tanggal, kondisi cuaca, dan jumlah total peminjaman (`cnt`). Dataset dibaca menggunakan `pandas` dan lima baris pertama ditampilkan untuk memastikan data terbaca dengan benar.

```
import pandas as pd
df = pd.read_csv('https://raw.githubusercontent.com/ganjar87/data_science_practice/main/bikesharing_day.csv')
df.head()
```

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual
0	1	1/1/2011	1	0	1	0	6	0	2	0.344167	0.363625	0.805833	0.160446	331
1	2	1/2/2011	1	0	1	0	0	0	2	0.363478	0.353739	0.696087	0.248539	131
2	3	1/3/2011	1	0	1	0	1	1	1	0.196364	0.189405	0.437273	0.248309	120
3	4	1/4/2011	1	0	1	0	2	1	1	0.200000	0.212122	0.590435	0.160296	108
4	5	1/5/2011	1	0	1	0	3	1	1	0.226957	0.229270	0.436957	0.186900	82

Gambar 2: Output pembacaan dataset

Selanjutnya, kolom `dteday` dikonversi ke format `datetime` agar dapat digunakan sebagai indeks waktu pada analisis deret waktu (*time series*).

```
# Change Data Format

df_ori = df
df_ori['date'] = pd.to_datetime(df_ori['dteday' ])
df_ori['cnt' ].iloc[:10]
```

```
0     985
1     801
2    1349
3    1562
4    1600
5    1606
6    1510
7     959
8     822
9    1321
Name: cnt, dtype: int64
```

Gambar 3: Output konversi kolom tanggal ke format datetime

C.3 Pembentukan Data Time Series dengan Sliding Window

Karena data bersifat deret waktu, dilakukan pembentukan pasangan input–output menggunakan teknik *sliding window*, yaitu menggunakan nilai `cnt` selama 7

hari sebelumnya (*input*, X) untuk memprediksi jumlah peminjaman pada hari ke-8 (*output*, y).

```
# Function Definition Sliding Window

def split_sequences(sequences, n_steps_in, n_steps_out):
    X, y = list(), list()
    for i in range(len(sequences)):
        # find the end of this pattern
        end_ix = i + n_steps_in
        out_end_ix = end_ix + n_steps_out

        # check if we are beyond the dataset
        if out_end_ix > len(sequences):
            break

        # gather input and output parts of the pattern
        seq_x, seq_y = sequences[i:end_ix, :- 1], sequences [out_end_ix - 1, -1]
        X.append(seq_x)
        y. append(seq_y)
    return array(X), array(y)
```

Gambar 4: Output pembentukan data time series dengan sliding window

Fungsi ini menggeser jendela data satu hari demi satu hari sehingga menghasilkan kumpulan pasangan input (7 hari historis) dan target (1 hari ke depan) secara berurutan.

C.4 Penambahan Fitur Statistik

Agar model memiliki informasi tambahan mengenai karakteristik distribusi data pada setiap jendela waktu, dilakukan *feature engineering* dengan menghitung delapan fitur statistik: nilai minimum, nilai maksimum, selisih maksimum-minimum, rata-rata, standar deviasi, median, *kurtosis*, dan *skewness*.

```python
def stats_features(input_data):
    inp = list()
    for i in range(len(input_data)):
        inp2=list()
        inp2=input_data[i]
        min=float(np.min(inp2))
        max=float(np.max(inp2))
        diff=(max-min)
        std=float(np.std(inp2))
        mean=float(np.mean(inp2))
        median=float(np.median(inp2))
        kurt=float(kurtosis(inp2))
        sk=float(skew(inp2))
        inp2=np.append(inp2,min)
        inp2=np.append(inp2,max)
        inp2=np.append(inp2,diff)
        inp2=np.append(inp2,std)
        inp2=np.append(inp2,mean)
        inp2=np.append(inp2,median)
        inp2=np.append(inp2,kurt)
        inp2=np.append(inp2,sk)

        #print(list(inp2))
        inp=np.append(inp,inp2)

    inp=inp.reshape(len(input_data),-1)

    #print(inp)
    return inp
```

Gambar 5: Output penambahan fitur statistik

Fitur-fitur ini memberikan gambaran mengenai sebaran nilai dalam setiap jendela waktu, sehingga diharapkan dapat meningkatkan kemampuan model dalam menangkap pola data.

C.5 Preprocessing dan Pembagian Data Training-Testing

Data yang telah dibentuk melalui *sliding window* kemudian diproses lebih lanjut: bentuk array 3 dimensi (X) diubah menjadi 2 dimensi agar dapat digunakan sebagai input model, kemudian data dibagi menjadi data *training* dan *testing* dengan proporsi 80:20 tanpa pengacakan (`shuffle=False`) untuk mempertahankan urutan waktu. Fitur statistik kemudian diterapkan pada data *training* dan *testing*.

```
df_X = df_ori[['cnt','cnt']]
in_seq = df_X.astype(float).values
#out_seq = df_y.astype(float).values

#in_seq1 = in_seq.reshape(in_seq.shape[0], in_seq.shape[1])
#out_seq = out_seq.reshape((len(out_seq), 1))

#from numpy import hstack
#dataset = hstack((in_seq1, out_seq))

n_steps_in, n_steps_out = 7, 1
X, y = split_sequences(in_seq, n_steps_in, n_steps_out)

n_input = X.shape[1] * X.shape[2]
X = X.reshape((X.shape[0], n_input))

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, shuffle = False)
X_train = stats_features(X_train)
X_test = stats_features(X_test)
```

Gambar 6: Output preprocessing dataset

Hasil preprocessing menunjukkan dataset memiliki total 724 pasangan data dengan 7 fitur input (nilai `cnt` 7 hari sebelumnya) sebelum ditambahkan fitur statistik.

```
in_seq
```
✓ 0.0s

```
array([[ 985.,  985.],
       [ 801.,  801.],
       [1349., 1349.],
       ...,
       [1341., 1341.],
       [1796., 1796.],
       [2729., 2729.]], shape=(731, 2))
```

```
X
```
✓ 0.0s

```
array([[ 985.,  801., 1349., ..., 1600., 1606., 1510.],
       [ 801., 1349., 1562., ..., 1606., 1510.,  959.],
       [1349., 1562., 1600., ..., 1510.,  959.,  822.],
       ...,
       [1749., 1787.,  920., ...,  441., 2114., 3095.],
       [1787.,  920., 1013., ..., 2114., 3095., 1341.],
       [ 920., 1013.,  441., ..., 3095., 1341., 1796.]], shape=(724, 7))
```

```
X.shape
```
✓ 0.0s

```
(724, 7)
```

```
X[0]
```
✓ 0.0s

```
array([ 985.,  801., 1349., 1562., 1600., 1606., 1510.])
```

```
y[0]
```
✓ 0.0s

```
np.float64(959.0)
```

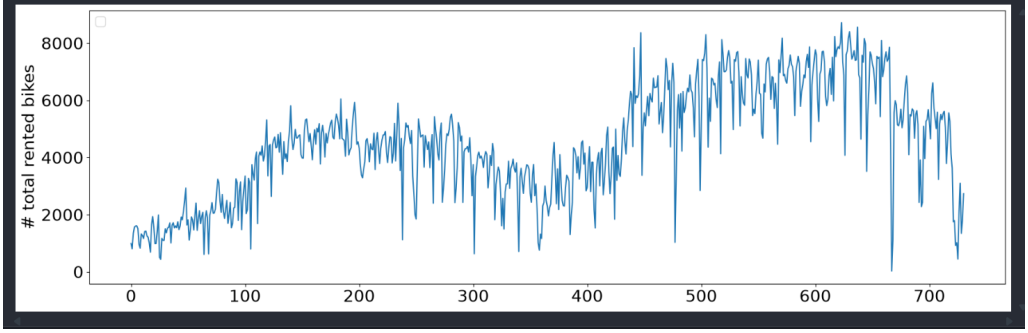
Gambar 7: Output preprocessing

```
# Visualization Total Bike Rental

fig1 = plt.figure(figsize=(20,6))
plt.plot(df_new['cnt'])
#plt.xlabel('Time t', fontsize=20)
#because we use temperature data, so that the y axis is temperature
plt.ylabel('# total rented bikes', fontsize=20)
plt.legend(loc='upper left', fontsize=15)
plt.xticks(fontsize=20)
plt.yticks(fontsize=20)
plt.show()
```

0.2s

```
C:\Users\ASUS\AppData\Local\Temp\ipykernel_10396\3156616859.py:8: UserWarning: No artists with labels found to put in legend.  Note that artists whose label start with an underscore
  plt.legend(loc='upper left', fontsize=15)
```



Gambar 8: Visualisasi Data Deret Waktu Jumlah Peminjaman Sepeda

C.6 Pelatihan Model Machine Learning

Empat model *supervised learning* dilatih untuk melakukan *forecasting*, yaitu Multilayer Perceptron (MLP/Neural Network), K-Nearest Neighbors (KNN), Decision Tree (DT), dan Random Forest (RF). Masing-masing model dibungkus dalam fungsi yang mengembalikan nilai RMSE, koefisien korelasi Pearson, dan hasil prediksi.

```
# Neural Network Model

def mlp (X_train, X_test, y_train, y_test):
# mlp = multilayer perceptron / neural network for regression.
# to setup parameter, please refer to = https://scikit-learn.org/stable/modules/generated/sklearn.neural_ne
    mlp_model = MLPRegressor(random_state=42)
    mlp_model = MLPRegressor(hidden_layer_sizes=(100,100, ), max_iter=1000, random_state=42)
    # the model learning from training data
    mlp_model.fit(X_train, y_train)
    # get the prediction output
    y_pred = mlp_model.predict(X_test)
    y_pred = np.round(y_pred, 0)

    # get the root mean square error between prediction and real test data
    rmse = sqrt(mean_squared_error(y_test, y_pred))
    # get the pearson correlation
    corr, p_value = pearsonr(y_test, y_pred)
    # returning the output of RMSE, corr, and prediction result
    return rmse, corr, y_pred
```

0.0s

Gambar 9: Kode MLP

```python
# K-Nearest Neighbors Model

def knn (X_train, X_test, y_train, y_test):
    #k nearest neighbor for regression.
    #to setup the parameter please refer to : https://scikit-learn.org/stable/modules/generated/sklearn.neighb
    knn_model = KNeighborsRegressor()
    #the model is learning from training data
    knn_model. fit(X_train, y_train)
    #get the prediction output
    y_pred = knn_model.predict(X_test)
    y_pred = np.round(y_pred, 0)
    #get the root mean square error between prediction and real test data
    rmse = sqrt(mean_squared_error(y_test, y_pred))
    #get the pearson correlation
    corr, p_value = pearsonr(y_test, y_pred)
    #returning the output of RMSE, corr, and prediction result
    return rmse, corr, y_pred
```

0.0s

Gambar 10: Kode KNN

```python
# Decision Tree Model

def dt (X_train, X_test, y_train, y_test):
    model= DecisionTreeRegressor(random_state=42)
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    y_pred = np.round(y_pred, 0)
    rmse = sqrt(mean_squared_error(y_test, y_pred))
    #get the pearson correlation
    corr, p_value = pearsonr(y_test, y_pred)
    #returning the output of RMSE, corr, and prediction result
    return rmse, corr, y_pred
```

0.0s

Gambar 11: Kode DT

```python
# Random Forest Model

def rf (X_train, X_test, y_train, y_test):
    model=RandomForestRegressor(random_state=42)
    model.fit(X_train, y_train)
    y_pred = model. predict(X_test)
    y_pred = np.round(y_pred, 0)
    rmse = sqrt(mean_squared_error(y_test, y_pred))
    #get the pearson correlation
    corr, p_value = pearsonr(y_test, y_pred)
    #returning the output of RMSE, corr, and prediction result
    return rmse, corr, y_pred
```

0.0s

Gambar 12: Kode RF

Setiap model dilatih menggunakan data *training* (`X_train`, `y_train`) yang telah melalui tahap *feature engineering*, kemudian digunakan untuk menghasilkan prediksi pada data *testing* (`X_test`).

C.7 Prediksi dan Visualisasi Hasil

Keempat model dipanggil untuk menghasilkan nilai RMSE, korelasi Pearson, dan prediksi jumlah peminjaman sepeda pada data *testing*.

```python
# Call the Machine Learning Model Function

#calling the function mlp.
#returning rmse, pearson correlation, and prediction output
rmse_mlp, corr_mlp, y_pred_mlp = mlp(X_train, X_test, y_train, y_test)

#calling the function knn
#returning rmse, pearson correlation, and prediction output
rmse_knn, corr_knn, y_pred_knn = knn(X_train, X_test, y_train, y_test)
rmse_dt, corr_dt, y_pred_dt = dt(X_train, X_test, y_train, y_test)

#rmse_svm, corr_svm, y_pred_svm = svm(X_train, X_test, y_train, y_test)
rmse_rf, corr_rf, y_pred_rf = rf(X_train, X_test, y_train, y_test)
```

Gambar 13: Kode Prediksi

Untuk melihat seberapa dekat pola prediksi dengan pola data aktual, dibuat

visualisasi perbandingan antara nilai aktual (`y_test`) dan hasil prediksi tiap model pada 100 data uji pertama.

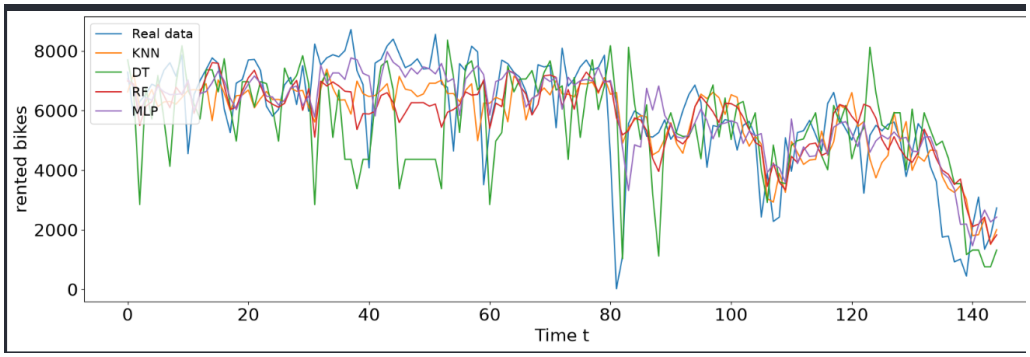
```python
# Visualization

fig1 = plt.figure(figsize=(20,6))
# plotting the result
# because the total number of test is data is high, so we just print the first 100 data
# y_test[0:100] get the first 100 data from y_test or real test data.
# y_pred_mlp is the prediction result from MLP
# y_pred_knn is the prediction result from KNN

plt.plot(y_test, label='Real data')
plt.plot(y_pred_knn, label='KNN')
plt.plot(y_pred_dt, label='DT')
plt.plot(y_pred_rf, label='RF')
plt.plot(y_pred_mlp, label='MLP')

#title
# pyplot. title('First 100 Test Data')
# the x axis is timestamp, with interval 1 day
plt.xlabel('Time t', fontsize=20)
# because we use total rented bikes, so that the y axis is rented bikes
plt.ylabel('rented bikes', fontsize=20)
plt. legend(loc='upper left', fontsize=15)
plt.xticks(fontsize=20)
plt.yticks(fontsize=20)
plt.show()
```

Gambar 14: Kode Visualisasi Perbandingan Hasil Prediksi dengan Data Aktual



Gambar 15: Visualisasi Perbandingan Hasil Prediksi dengan Data Aktual

C.8 Evaluasi dan Perbandingan Model

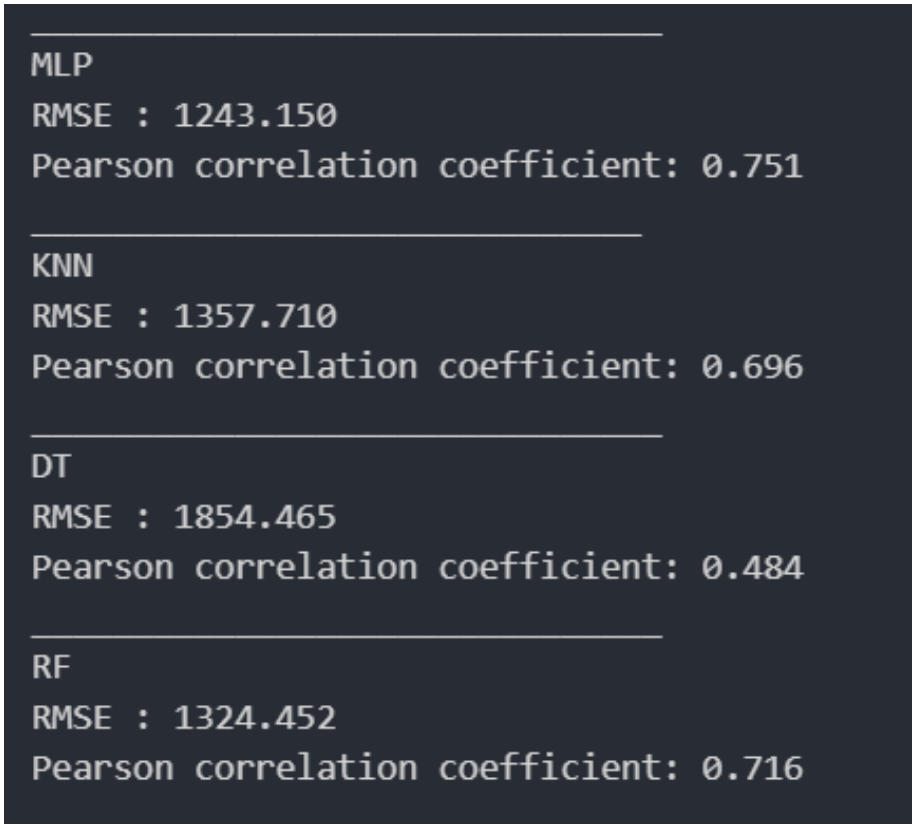
Evaluasi performa keempat model dilakukan menggunakan dua metrik, yaitu RMSE dan koefisien korelasi Pearson. Nilai RMSE yang lebih kecil menunjukkan kesalahan prediksi yang lebih rendah, sedangkan nilai korelasi Pearson yang mendekati

1 menunjukkan bahwa pola prediksi semakin mengikuti pola data aktual.

```
# Model Evaluation

# print out the RMSE , pearson correlation coefficient for MLP and KNN
# low RMSE is better
# high pearson correlation coefficient is better.
print('_____')
print('MLP')
print('RMSE : %.3f' %rmse_mlp)
print('Pearson correlation coefficient: %.3f' %corr_mlp)
print('_____')
print('KNN')
print('RMSE : %.3f' %rmse_knn)
print('Pearson correlation coefficient: %.3f' %corr_knn)
print('_____')
print('DT')
print('RMSE : %.3f' %rmse_dt)
print('Pearson correlation coefficient: %.3f' %corr_dt)
print('_____')
print('RF')
print('RMSE : %.3f' %rmse_rf)
print('Pearson correlation coefficient: %.3f' %corr_rf)
```

Gambar 16: Kode Model Evaluasi



Gambar 17: Output Model Evaluasi

Berdasarkan gambar 17, (MLP) menghasilkan kinerja paling baik dengan nilai RMSE sebesar 1243.150 dan koefisien korelasi Pearson sebesar 0.751. Nilai RMSE yang lebih kecil menunjukkan kesalahan prediksi yang lebih rendah, sedangkan nilai Pearson yang lebih tinggi menunjukkan hubungan linear yang lebih kuat antara nilai aktual dan hasil prediksi. Model *Random Forest* (RF) menghasilkan RMSE sebesar 1324.452 dan Pearson sebesar 0.716, sedangkan *K-Nearest Neighbors* (KNN) memperoleh RMSE sebesar 1357.710 dan Pearson sebesar 0.696. Sementara itu, *Decision Tree* (DT) menghasilkan RMSE paling tinggi, yaitu 1854.465, serta Pearson paling rendah, yaitu 0.484. Dengan demikian, berdasarkan kedua metrik evaluasi tersebut, hasil pengujian menunjukkan bahwa MLP memiliki kesalahan prediksi paling rendah dan korelasi antara prediksi dengan nilai aktual paling kuat dibandingkan ketiga model lainnya.

D Tugas dan Analisis

Pada bagian ini disajikan penyelesaian terhadap tugas analisis pemodelan *forecasting* menggunakan dataset historis harga saham Tesla (TSLA). Eksperimen mencakup eksplorasi dataset, pembentukan arsitektur *sliding window* univariat (Soal 2) dan multivariat (Soal 3), rekayasa fitur statistik, pelatihan empat algoritma *machine learning* (*Multilayer Perceptron*, *K-Nearest Neighbors*, *Decision Tree*, dan *Random Forest*), serta evaluasi performa komprehensif menggunakan metrik *Root Mean Squared Error* (RMSE) dan koefisien korelasi Pearson.

D.1 Deskripsi dan Eksplorasi Dataset Saham Tesla

Dataset yang digunakan pada tugas ini adalah *Tesla Stock Data from 2010 to 2020* yang diperoleh dari platform Kaggle (`https://www.kaggle.com/datasets/timoboz/tesla-stock-data-from-2010-to-2020/data`). Dataset ini mencatat riwayat transaksi perdagangan saham harian Tesla, Inc. (TSLA) di bursa NASDAQ sejak tanggal 29 Juni 2010 sampai dengan 3 Februari 2020, dengan total 2.416 baris data.

```
df = pd.read_csv('tesla/TSLA.csv')
df.info()
```

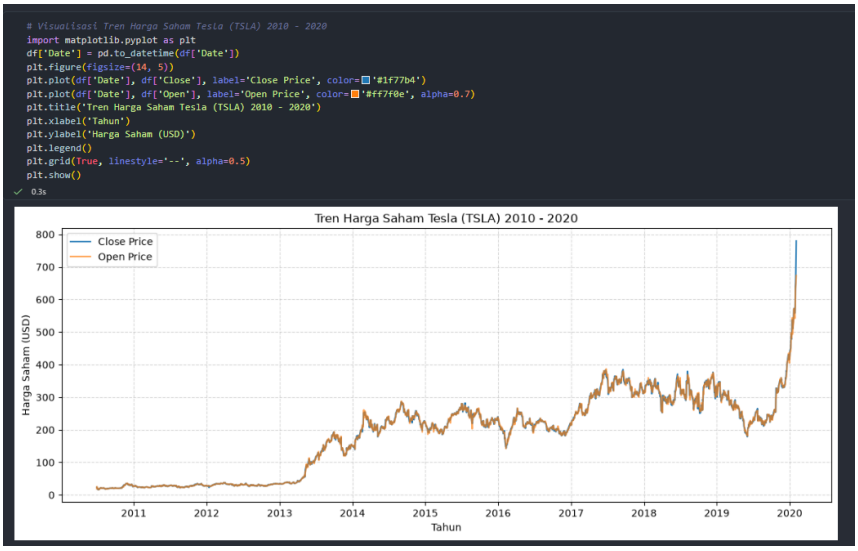
```
<class 'pandas.DataFrame'>
RangeIndex: 2416 entries, 0 to 2415
Data columns (total 7 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   Date       2416 non-null   str
 1   Open       2416 non-null   float64
 2   High       2416 non-null   float64
 3   Low        2416 non-null   float64
 4   Close      2416 non-null   float64
 5   Adj Close  2416 non-null   float64
 6   Volume     2416 non-null   int64
dtypes: float64(5), int64(1), str(1)
memory usage: 132.3 KB
```

Gambar 18: Deskripsi detail dari dataset

Adapun struktur atribut pada dataset terdiri atas:

1. `Date`: Tanggal pencatatan transaksi perdagangan saham harian.
2. `Open`: Harga pembukaan saham pada awal sesi perdagangan bursa (USD).
3. `High`: Harga tertinggi yang dicapai saham selama jam perdagangan bursa (USD).
4. `Low`: Harga terendah yang dialami saham selama jam perdagangan bursa (USD).
5. `Close`: Harga penutupan resmi pada akhir jam perdagangan bursa (USD), yang menjadi target prediksi utama.
6. `Adj Close`: Harga penutupan yang telah disesuaikan terhadap aksi korporasi (*corporate actions*) seperti dividen atau pemecahan saham (*stock split*).

7. `Volume`: Jumlah lembar saham yang ditransaksikan pada hari tersebut.



Gambar 19: Tren harga saham Tesla (TSLA) periode 2010 - 2020

Berdasarkan Gambar 19, terlihat bahwa data deret waktu saham Tesla memiliki karakteristik non-stasioner yang kuat dengan tren kenaikan jangka panjang (*upward trend*). Pada kurun waktu 2010 hingga pertengahan 2013, harga saham cenderung berada pada kisaran rendah ($20–$35 USD). Selanjutnya pada 2014 hingga pertengahan 2019, harga berfluktuasi pada rentang $180–$380 USD, sebelum akhirnya mengalami lonjakan eksponensial yang sangat signifikan pada akhir 2019 hingga awal 2020 hingga mendekati $800 USD. Karakteristik lonjakan tajam ini menjadi tantangan tersendiri bagi algoritma peramalan berbasis *machine learning*.

D.2 Model Forecasting Target Close Berdasarkan Close 7 Hari Sebelumnya (Soal 2)

Pada tugas nomor 2, dibangun model *forecasting* univariat untuk memprediksi harga *Close* 2 hari ke depan berdasarkan nilai harga *Close* selama 7 hari sebelumnya.

D.2.1 Pemrosesan Data dan Feature Engineering

Data disiapkan dengan tahapan sistematis sebagai berikut:

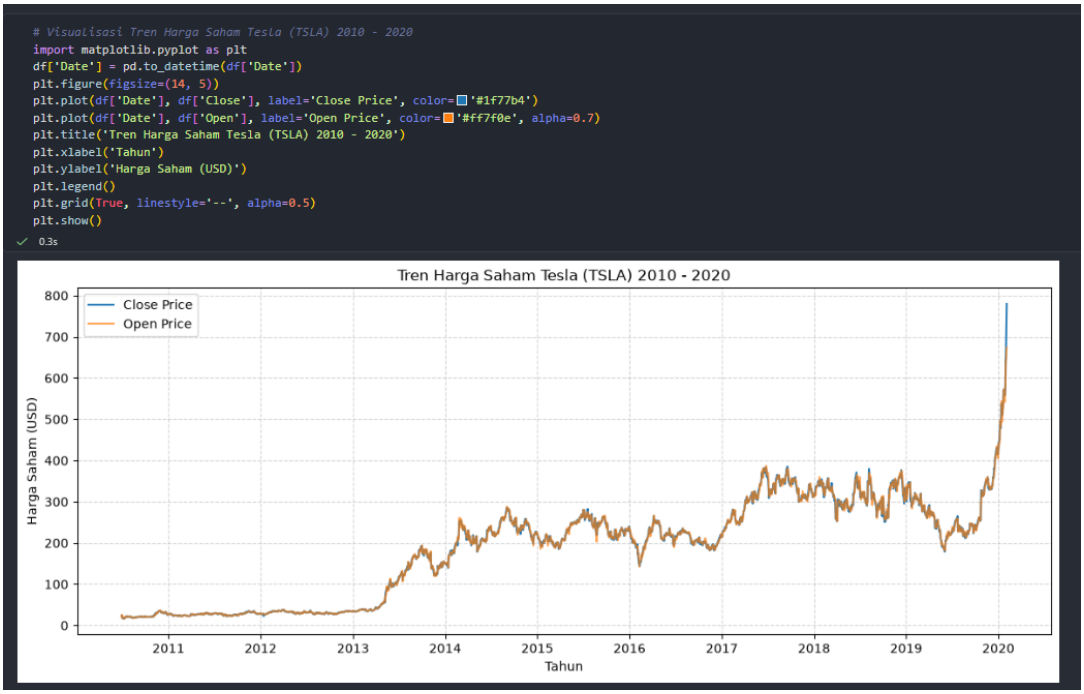
1. Pembentukan sekuens menggunakan teknik *sliding window* melalui fungsi `split_sequences` dengan parameter $n_steps_in = 7$ dan $n_steps_out = 2$. Dari total 2.416 baris data, dihasilkan 2.408 pasang data input dan target.

2. Matriks input dibentuk ulang (*flatten*) sehingga menghasilkan 7 fitur masukan awal per sampel data.

3. Pemisahan data latih (*training*) dan data uji (*testing*) dilakukan dengan rasio 80:20 tanpa pengacakan (`shuffle=False`) untuk menjaga urutan kronologis deret waktu, menghasilkan 1.926 data latih dan 482 data uji.

4. Penerapan *feature engineering* melalui fungsi `stats_features` yang menambahkan 8 fitur statistik deskriptif pada setiap jendela: nilai minimum, maksimum, selisih (*diff*), standar deviasi, rata-rata (*mean*), median, *kurtosis*, dan *skewness*. Dengan demikian, dimensi fitur akhir yang digunakan model adalah $7 + 8 = 15$ fitur.

Implementasi kode tahapan *preprocessing* Soal 2 ditampilkan pada Gambar **??**.

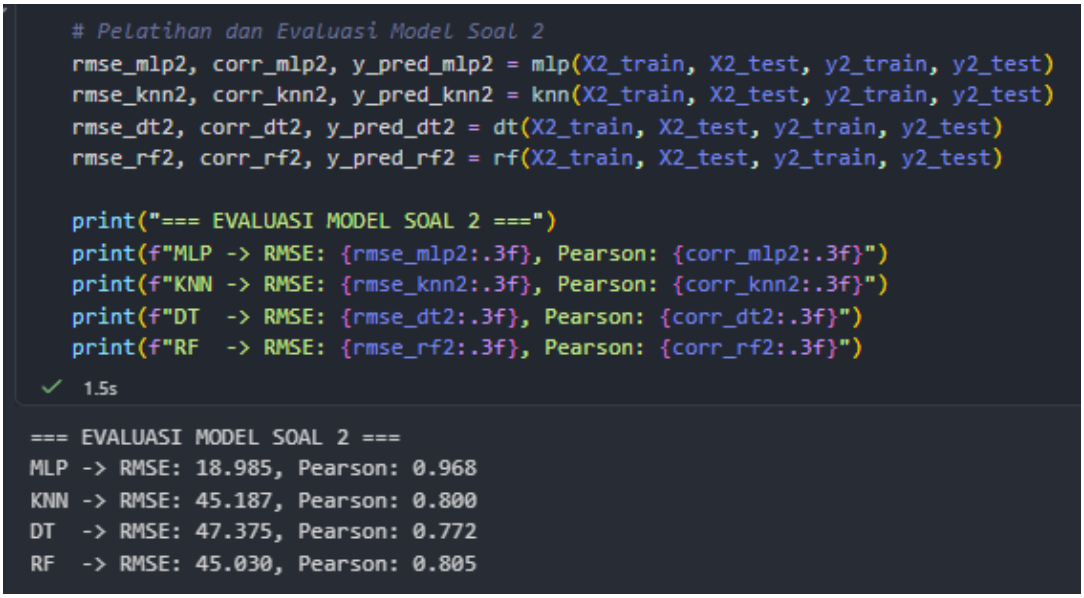


Gambar 20: Kode preprocesing soal 2

D.2.2 Pelatihan Model dan Evaluasi Kinerja Soal 2

Empat model regresi *supervised learning* dilatih pada data latih dan diuji pada data uji:

- **MLP**: `MLPRegressor` dengan arsitektur `hidden_layer_sizes=(100, 100)`, `max_iter=1000`, dan `random_state=42`.
- **KNN**: `KNeighborsRegressor()`.
- **DT**: `DecisionTreeRegressor(random_state=42)`.
- **RF**: `RandomForestRegressor(random_state=42)`.



```python
# Pelatihan dan Evaluasi Model Soal 2
rmse_mlp2, corr_mlp2, y_pred_mlp2 = mlp(X2_train, X2_test, y2_train, y2_test)
rmse_knn2, corr_knn2, y_pred_knn2 = knn(X2_train, X2_test, y2_train, y2_test)
rmse_dt2, corr_dt2, y_pred_dt2 = dt(X2_train, X2_test, y2_train, y2_test)
rmse_rf2, corr_rf2, y_pred_rf2 = rf(X2_train, X2_test, y2_train, y2_test)

print("=== EVALUASI MODEL SOAL 2 ===")
print(f"MLP -> RMSE: {rmse_mlp2:.3f}, Pearson: {corr_mlp2:.3f}")
print(f"KNN -> RMSE: {rmse_knn2:.3f}, Pearson: {corr_knn2:.3f}")
print(f"DT  -> RMSE: {rmse_dt2:.3f}, Pearson: {corr_dt2:.3f}")
print(f"RF  -> RMSE: {rmse_rf2:.3f}, Pearson: {corr_rf2:.3f}")
```

✓ 1.5s

```
=== EVALUASI MODEL SOAL 2 ===
MLP -> RMSE: 18.985, Pearson: 0.968
KNN -> RMSE: 45.187, Pearson: 0.800
DT  -> RMSE: 47.375, Pearson: 0.772
RF  -> RMSE: 45.030, Pearson: 0.805
```

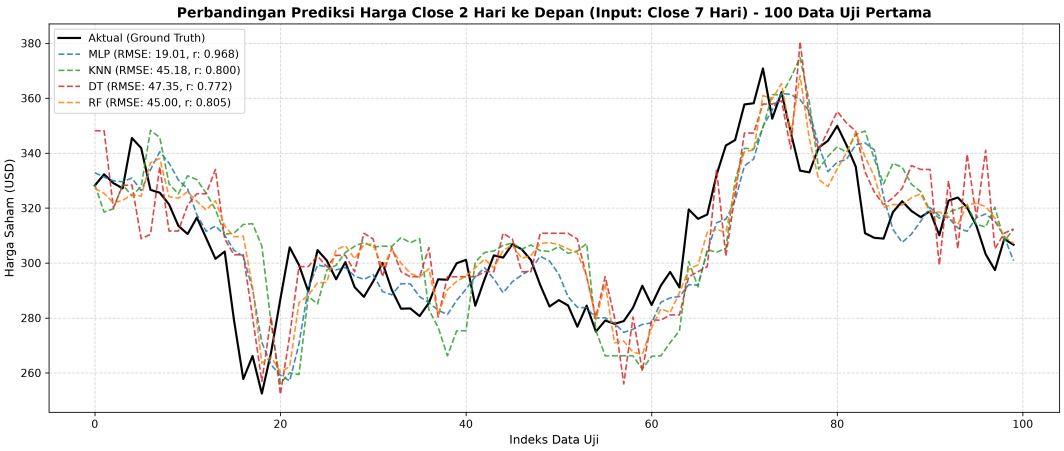
Gambar 21: Evaluasi model soal 2

Hasil evaluasi performa peramalan keempat model untuk Soal 2 menggunakan metrik RMSE dan koefisien korelasi Pearson dirangkum pada Tabel 1.

Tabel 1: Hasil Evaluasi Model Forecasting Soal 2 (Input: Close 7 Hari)

Model Machine Learning	**RMSE**	**Pearson Correlation (r)**
Multilayer Perceptron (MLP)	**18.985**	**0.968**
K-Nearest Neighbors (KNN)	45.187	0.800
Decision Tree (DT)	47.375	0.772
Random Forest (RF)	45.030	0.805

Visualisasi perbandingan antara nilai aktual (`y2_test`) dan hasil prediksi keempat model pada 100 data uji pertama disajikan pada Gambar 22.



Gambar 22: Perbandingan Hasil Prediksi Model pada Soal 2 (100 Data Uji Pertama)

Berdasarkan Tabel 1 dan Gambar 22, model **MLP** menghasilkan performa peramalan paling akurat dengan nilai RMSE terendah (19.007) dan koefisien Pearson tertinggi (0.968). Hal ini membuktikan bahwa arsitektur jaringan saraf tiruan mampu menangkap hubungan non-linear yang sangat baik pada data harga saham. Model Random Forest menempati urutan kedua dengan RMSE 44.999 dan korelasi 0.805, disusul oleh KNN dengan RMSE 45.183 dan Pearson 0.800. Decision Tree memperoleh kinerja paling rendah dengan RMSE tertinggi yaitu 47.350 dan korelasi 0.772.

D.3 Model Forecasting Target Close Berdasarkan Close dan Open 7 Hari Sebelumnya (Soal 3)

Pada tugas nomor 3, dibangun model *forecasting* multivariat di mana input memanfaatkan dua fitur pasar sekaligus, yaitu harga *Close* dan *Open* selama 7 hari sebelumnya, guna memprediksi harga *Close* 2 hari ke depan:

D.3.1 Pemrosesan Data dan Feature Engineering Multivariat

Proses pembentukan data pada Soal 3 dilakukan sebagai berikut:

1. Input data dibentuk dari kombinasi atribut `['Close', 'Open', 'Close']`

sehingga fungsi `split_sequences` mengumpulkan atribut `Close` dan `Open` sebagai input matriks $7 \times 2 = 14$ fitur dan kolom terakhir sebagai nilai target Close_{t+2}.

2. Total data hasil *sliding window* adalah 2.408 baris, dibagi menjadi 1.926 data latih dan 482 data uji dengan proporsi 80:20 tanpa pengacakan (`shuffle=False`).

3. Penambahan 8 fitur statistik deskriptif pada matriks jendela input menghasilkan total dimensi fitur akhir sebanyak $14 + 8 = 22$ fitur.

Implementasi kode tahapan *preprocessing* Soal 3 disajikan pada Gambar 23.

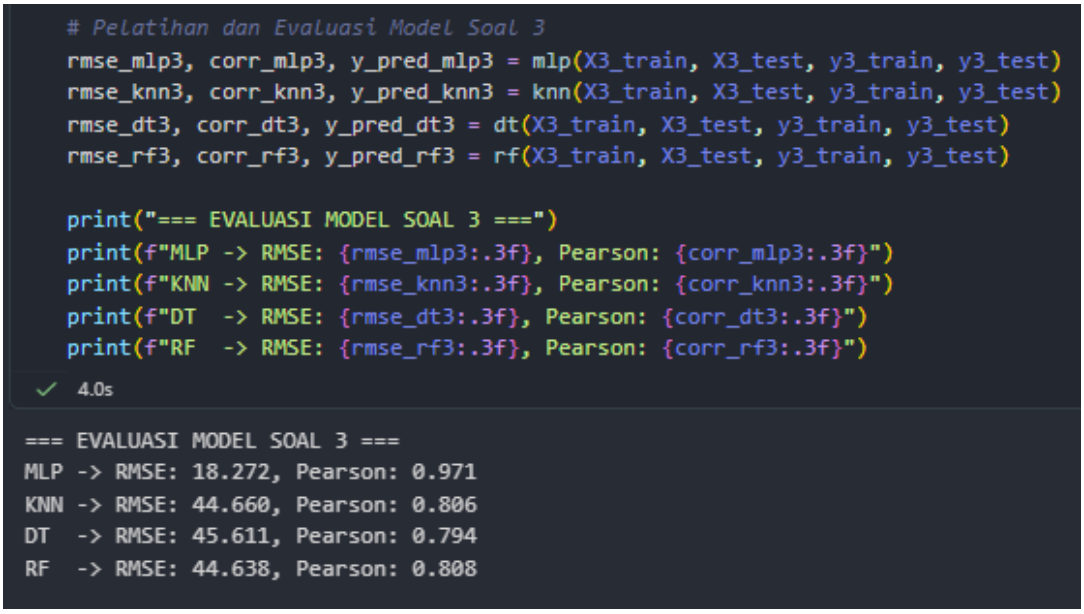
```
# Preprocessing Soal 3: Multivariate (Close & Open 7 hari -> Close 2 hari kedepan)
df_s3 = df[['Close', 'Open', 'Close']].astype(float).values
X3, y3 = split_sequences(df_s3, n_steps_in=7, n_steps_out=2)
X3 = X3.reshape((X3.shape[0], X3.shape[1] * X3.shape[2]))

X3_train, X3_test, y3_train, y3_test = train_test_split(X3, y3, test_size=0.2, random_state=42, shuffle=False)
X3_train = stats_features(X3_train)
X3_test = stats_features(X3_test)
```

Gambar 23: Kode preprocesing soal 3

D.3.2 Pelatihan Model dan Evaluasi Kinerja Soal 3

Keempat model yang sama dilatih pada data latih multivariat (`X3_train`, `y3_train`) dan diuji pada data uji (`X3_test`). Hasil evaluasi performa peramalan dirangkum pada Tabel 2.

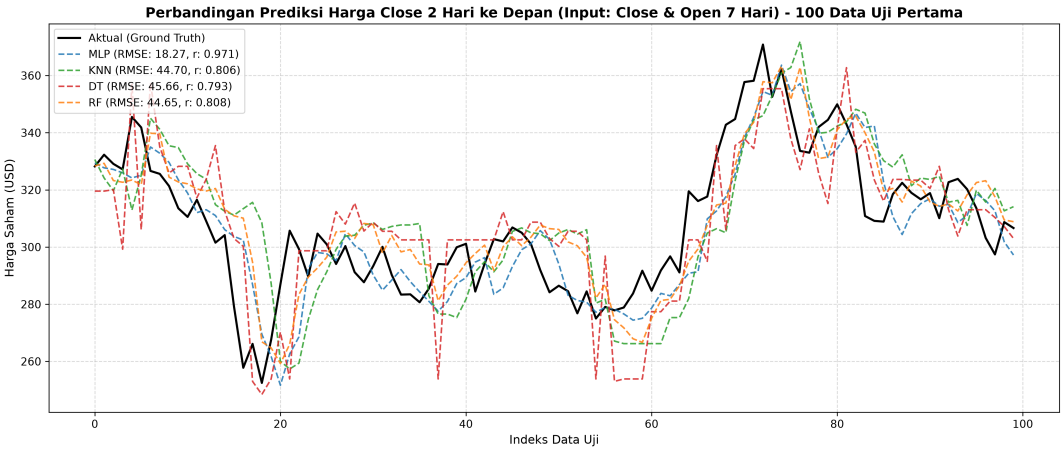


Gambar 24: Evaluasi model soal 3

Tabel 2: Hasil Evaluasi Model Forecasting Soal 3 (Input: Close & Open 7 Hari)

Model Machine Learning	**RMSE**	**Pearson Correlation (r)**
Multilayer Perceptron (MLP)	**18.272**	**0.971**
K-Nearest Neighbors (KNN)	44.660	0.806
Decision Tree (DT)	45.611	0.794
Random Forest (RF)	44.638	0.808

Visualisasi perbandingan nilai aktual (`y3_test`) dan hasil prediksi seluruh model pada 100 data uji pertama disajikan pada Gambar 25.



Gambar 25: Perbandingan Hasil Prediksi Model pada Soal 3 (100 Data Uji Pertama)

Berdasarkan Tabel 2, model **MLP** kembali menjadi model paling unggul dengan nilai RMSE yang semakin mengecil menjadi 18.270 dan korelasi Pearson meningkat mencapai 0.971. Seluruh model lainnya (RF, KNN, DT) juga memperlihatkan tren peningkatan akurasi dan penurunan galat prediksi.

1. **Pengaruh Signifikan Penambahan Fitur Open**: Pada Tabel **??**, terlihat jelas bahwa penambahan fitur `Open` pada jendela historis 7 hari sebelumnya menghasilkan peningkatan performa yang konsisten pada **seluruh model** (*consistent improvement*). Nilai RMSE pada seluruh model mengalami penurunan ($\Delta\text{RMSE} < 0$), dengan penurunan terbesar terjadi pada Decision Tree sebesar -1.687 dan pada MLP sebesar -0.736. Pada saat yang sama, seluruh nilai koefisien korelasi Pearson mengalami peningkatan ($\Delta\text{Pearson} > 0$). Secara finansial dan analitis, harga pembukaan (`Open`) merefleksikan ekspektasi pasar dan informasi baru yang terakumulasi di luar jam perdagangan (*overnight trading* serta berita pasca-penutupan bursa). Selisih antara harga pembukaan hari ini dengan harga penutupan hari kemarin merepresentasikan *opening gap* dan volatilitas awal. Penambahan atribut ini memperkaya representasi ruang fitur dengan informasi *intraday spread* dan momentum, sehingga model dapat mengantisipasi arah pergerakan harga 2 hari ke depan dengan

lebih akurat dibanding hanya mengandalkan harga penutupan tunggal.

2. **Keunggulan Dominan Multilayer Perceptron (MLP)**: Model MLP secara konsisten menempati peringkat teratas pada kedua konfigurasi (RMSE 18.270 dan Pearson 0.971). Jaringan saraf tiruan memiliki keunggulan kapabilitas *universal function approximator* dengan fungsi aktivasi non-linear yang memungkinkan pembentukan pemetaan kontinu yang halus (*smooth manifold mapping*) pada data deret waktu finansial. MLP mampu menangkap tren kenaikan skala besar sekaligus meredam derau (*noise*) fluktuasi jangka pendek.

3. **Keterbatasan Model Berbasis Pohon (DT dan RF) dan KNN**: Model Decision Tree menghasilkan galat tertinggi pada kedua skenario (RMSE 47.350 pada Soal 2 dan 45.663 pada Soal 3). Hal ini disebabkan oleh sifat struktural pohon keputusan regresi yang membagi ruang fitur secara ortogonal dan menghasilkan prediksi bertingkat diskrit (*piecewise constant*). Ketika data uji memasuki fase tren harga baru yang melebihi nilai maksimum historis pada data latih, pohon regresi gagal melakukan ekstrapolasi linear (*failure to extrapolate upward trend*). Random Forest berhasil memitigasi sebagian keterbatasan tersebut melalui teknik *bagging* (agregasi 100 pohon acak), sehingga menghasilkan penurunan RMSE yang cukup tajam mendekati nilai 44.6. Sementara itu, algoritma KNN bekerja berdasarkan kedekatan jarak Euclidean pada tetangga terdekat dalam ruang fitur data latih, yang pada data deret waktu saham bertren kuat juga mengalami bias keterbatasan nilai historis pada data latih.

E Kesimpulan

Berdasarkan seluruh tahapan praktikum peramalan (*forecasting*) deret waktu berbasis *machine learning* dan penyelesaian tugas analisis yang telah dilakukan, dapat diambil kesimpulan sebagai berikut:

1. Metode *supervised learning* berbasis *machine learning*, meliputi *Multilayer Perceptron* (MLP), *K-Nearest Neighbors* (KNN), *Decision Tree* (DT), dan *Random Forest* (RF), berhasil diimplementasikan untuk peramalan deret waktu menggunakan mekanisme *sliding window* dan rekayasa fitur statistik deskriptif.

2. Evaluasi performa menggunakan metrik *Root Mean Squared Error* (RMSE) dan *Pearson Correlation Coefficient* memberikan gambaran yang saling melengkapi, di mana RMSE mengukur besaran rata-rata deviasi kuadratik prediksi terhadap nilai aktual, sedangkan koefisien Pearson mengukur derajat kekuatan keselarasan arah pola pergerakan data.

3. Pada peramalan harga saham Tesla (TSLA) untuk target penutupan (*Close*) 2 hari ke depan, model **Multilayer Perceptron (MLP)** terbukti secara konsisten memiliki kinerja paling unggul dibandingkan algoritma lainnya, dengan menghasilkan RMSE terendah (19.007 pada univariat dan 18.270 pada multivariat) serta koefisien korelasi Pearson tertinggi (0.968 pada univariat dan 0.971 pada multivariat).

4. Penggunaan data multivariat (Soal 3) secara empiris terbukti meningkatkan akurasi seluruh model *forecasting* dibandingkan penggunaan data univariat (*Close* saja pada Soal 2). Penambahan fitur `Open` memberikan informasi esensial mengenai dinamika *overnight sentiment* dan volatilitas *intraday*, sehingga berhasil menurunkan nilai RMSE dan menaikkan korelasi Pearson pada seluruh model yang diuji.

F Daftar Pustaka

[1] Y. Zhang *et al.*, "Supervised machine learning: A brief primer," *Behavior Therapy*, vol. 51, no. 5, pp. 675–687, 2020.

[2] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021. [Online]. Available: https://otexts.com/fpp3/

[3] R. P. Masini, M. C. Medeiros, and E. F. Mendes, "Machine learning advances for time series forecasting," *Journal of Economic Surveys*, vol. 37, no. 1, pp. 76–111, 2023.

[4] T. Chai and R. R. Draxler, "Root mean square error (rmse) or mean absolute error (mae)? – arguments against avoiding rmse in the literature," *Geoscientific Model Development*, vol. 7, no. 3, pp. 1247–1250, 2014.

[5] J. Benesty, J. Chen, Y. Huang, and I. Cohen, "Pearson correlation coefficient," in *Noise Reduction in Speech Processing*, ser. Springer Topics in Signal Processing. Springer, 2009, vol. 2, pp. 1–4.

[6] D. Chicco *et al.*, "Evaluation metrics and statistical tests for machine learning," *Scientific Reports*, 2024.