LAPORAN PRAKTIKUM

PRAKTIKUM PENAMBANGAN DATA

PERTEMUAN 2

EXPLORATORY DATA ANALYSIS DAN DATA PREPROCESSING



Disusun oleh:

Nama	:	Hanan Fijananto
NIM	:	24/538946/SV/24555
Kelas	:	A2
Dosen Pengampu	:	Dr.Imam Fahrurrozi, S.T., M.Cs.

PROGRAM STUDI D-IV TEKNOLOGI REKAYASA PERANGKAT LUNAK

DEPARTEMEN TEKNIK ELEKTRO DAN INFORMATIKA

SEKOLAH VOKASI

UNIVERSITAS GADJAH MADA

YOGYAKARTA

2026

A Tujuan

1. Mahasiswa diharapkan mampu memahami konsep dasar Artificial Intelligence (AI) dan Machine Learning (ML).
2. Mahasiswa diharapkan mampu mengetahui dasar-dasar Machine Learning (ML)
3. Mahasiswa diharapkan mampu memahami konsep dasar Data Mining dan Data Preprocessing.

B Dasar Teori

B.1 Artificial Intelligence (AI)

Artificial Intelligence adalah teknologi yang memungkinkan mesin atau komputer untuk meniru kemampuan kognitif manusia. AI atau kecerdasan buatan adalah sistem yang dapat memahami, belajar, dan berpikir layaknya manusia dalam beberapa aspek, seperti mengenali pola, membuat prediksi, dan menyelesaikan masalah kompleks. Penggunaan AI sudah sangat luas dalam berbagai bidang, termasuk bisnis, kesehatan, dan hiburan.

AI juga mencakup berbagai teknologi, seperti machine learning, deep learning, dan natural language processing (NLP). Machine learning memungkinkan komputer belajar dari data dan pengalaman tanpa perlu diprogram secara eksplisit. Sementara itu, NLP digunakan untuk memungkinkan mesin memahami bahasa manusia, seperti yang kita temui pada asisten virtual seperti Siri dan Google Assistant [1].

B.2 Machine Learning (ML)

Teknologi machine learning (ML) adalah mesin yang dikembangkan untuk bisa belajar dengan sendirinya tanpa arahan dari penggunanya. Pembelajaran mesin dikembangkan berdasarkan disiplin ilmu lainnya seperti statistika, matematika dan

data mining sehingga mesin dapat belajar dengan menganalisis data tanpa perlu di program ulang atau diperintah.

Dalam hal ini machine learning memiliki kemampuan untuk memperoleh data yang ada dengan perintah ia sendiri. ML juga dapat mempelajari data yang ada dan data yang ia peroleh sehingga bisa melakukan tugas tertentu. Tugas yang dapat dilakukan oleh ML pun sangat beragam, tergantung dari apa yang ia pelajari [2].

B.3 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) atau dikenal juga dengan analisis data eksploratif merupakan pendekatan analisis untuk suatu data untuk membuat gambaran keseluruhan (summary) data, sehingga mudah untuk dipahami. Metode analisis ini menyediakan berbagai alat untuk meringkas dan memperoleh wawasan tentang sekumpulan data dengan cepat menggunakan grafik sebagai bentuk visualisasi data, tanpa menggunakan model statistik, atau formulasi hipotesis [3].

B.4 Data Preprocessing

Data preprocessing adalah proses mempersiapkan data mentah agar siap digunakan dalam analisis atau model machine learning. Tahapan ini mencakup pembersihan data, transformasi, integrasi, dan reduksi untuk memastikan data berkualitas tinggi, bebas dari noise, serta dalam format yang sesuai. Dengan preprocessing yang baik, model dapat belajar lebih efektif, menghindari bias, dan menghasilkan prediksi yang lebih akurat [4].

C Hasil dan Pembahasan

C.1 Exploratory Data Analysis (EDA)

C.1.1 Import Library

Ada 3 library yang digunakan untuk melakukan EDA, yaitu Pandas, Matplotlib, dan Seaborn. Pandas digunakan untuk memanipulasi data, Matplotlib digunakan untuk membuat visualisasi data, dan Seaborn digunakan untuk membuat visualisasi data yang lebih kompleks dan menarik.

Pada pertemuan sebelumnya, praktikan telah menginstall library pandas dan numpy. Namun, untuk library matplotlib, praktikan perlu menginstallnya terlebih dahulu menggunakan perintah:

```
pip install matplotlib
```

Berikut adalah kode untuk mengimpor library yang digunakan dalam EDA:

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
```

C.1.2 Load Dataset

Dataset yang akan digunakan di dalam praktikum ini diambil dari kaggle dengan link `https://www.kaggle.com/datasets/sakshigoyal7/credit-card-customers` Untuk membaca dataset, praktikan dapat menggunakan perintah:

```
df_churning =
   pd.read_csv('https://raw.githubusercontent.com/ganjar87
/data_science_practice/main/BankChurners.csv',
   delimiter=',')
```

C.1.3 Melihat 5 baris pertama dataset

Untuk melihat 5 baris pertama dataset, praktikan dapat menggunakan perintah:

```
df_churning = pd.read_csv('https://raw.githubusercontent.com/ganjar87/data_science_practice/main/BankChurners.csv', delimiter=',')
df_churning.head()
```

✓ 0.8s

	CLIENTNUM	Attrition_Flag	Customer_Age	Gender	Dependent_count	Education_Level	Marital_Status	Income_Category	Card_Category	Mo
0	768805383	Existing Customer	45	M	3	High School	Married	$60K - $80K	Blue	
1	818770008	Existing Customer	49	F	5	Graduate	Single	Less than $40K	Blue	
2	713982108	Existing Customer	51	M	3	Graduate	Married	$80K - $120K	Blue	
3	769911858	Existing Customer	40	F	4	High School	Unknown	Less than $40K	Blue	
4	709106358	Existing Customer	40	M	3	Uneducated	Married	$60K - $80K	Blue	

5 rows × 21 columns

Gambar 1: Membuat array dengan string sebagai member

C.1.4 Melihat 5 baris terakhir dataset

Untuk melihat 5 baris terakhir dataset, praktikan dapat menggunakan perintah:

```
df_churning.tail()
```

✓ 0.0s

	CLIENTNUM	Attrition_Flag	Customer_Age	Gender	Dependent_count	Education_Level	Marital_Status	I
10122	772366833	Existing Customer	50	M	2	Graduate	Single	
10123	710638233	Attrited Customer	41	M	2	Unknown	Divorced	
10124	716506083	Attrited Customer	44	F	1	High School	Married	
10125	717406983	Attrited Customer	30	M	2	Graduate	Unknown	
10126	714337233	Attrited Customer	43	F	2	Graduate	Married	

5 rows × 21 columns

Gambar 2: Membuat array dengan string sebagai member

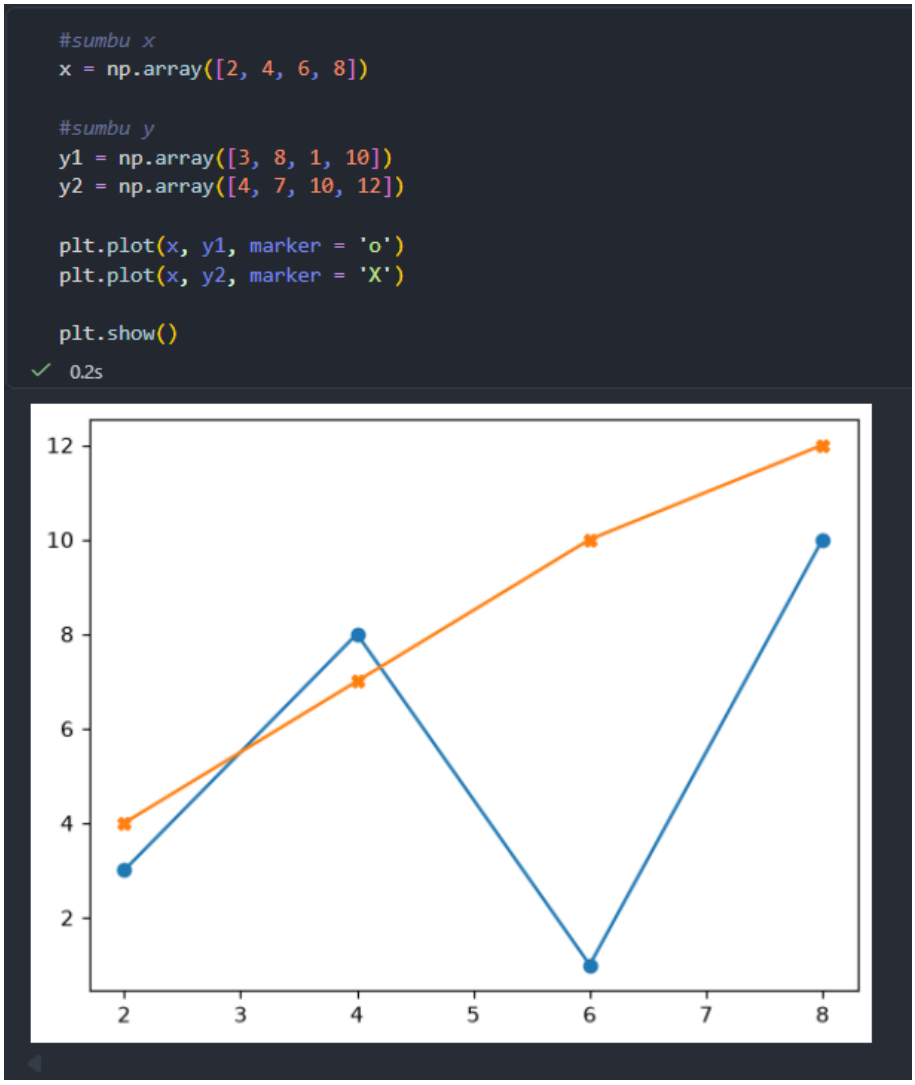
C.1.5 Menyimpan nilai dari class menjadi 2 dataframe yang berbeda

```
existing_data = df_churning[(df_churning.Attrition_Flag ==
    'Existing Customer')]
attrited_data = df_churning[(df_churning.Attrition_Flag ==
    'Attrited Customer')]
```

Kode tersebut digunakan untuk menyimpan nilai dari class menjadi 2 dataframe yang berbeda, yaitu existing_data dan attrited_data. Dataframe existing_data berisi data pelanggan yang masih aktif, sedangkan dataframe attrited_data berisi data pelanggan yang sudah tidak aktif (churn).

C.1.6 Line Chart

Untuk membuat line chart, praktikan dapat menggunakan data dummy terlebih dahulu seperti pada gambar 3.

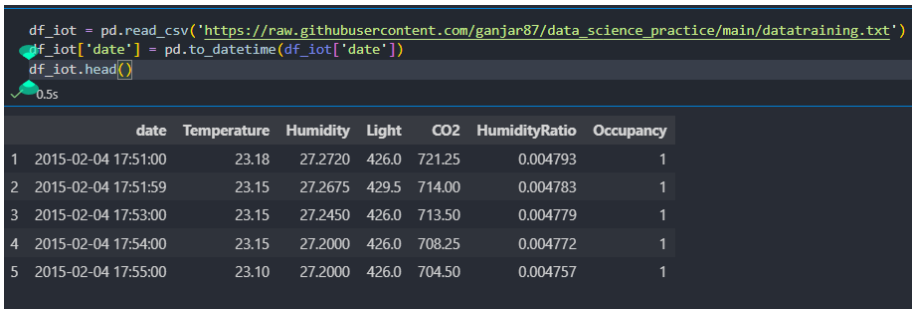


Gambar 3: Linechart dari data dummy

Berdasarkan gambar 3, Kode tersebut digunakan untuk membuat grafik garis

dengan dua data menggunakan library *Matplotlib*. Variabel x berisi data untuk **sumbu** x, sedangkan y_1 dan y_2 berisi data untuk **sumbu** y. Perintah `plt.plot(x, y1, marker='o')` digunakan untuk membuat garis pertama dengan penanda berbentuk lingkaran, sedangkan `plt.plot(x, y2, marker='X')` digunakan untuk membuat garis kedua dengan penanda berbentuk X. Terakhir, `plt.show()` digunakan untuk menampilkan grafik yang telah dibuat.

Setelah mencoba membuat line chart dengan data dummy, praktikan dapat mencoba membuat line chart dengan data yang ada pada dataset ioT untuk menampilkan perubahan nilai sensor terhadap waktu.



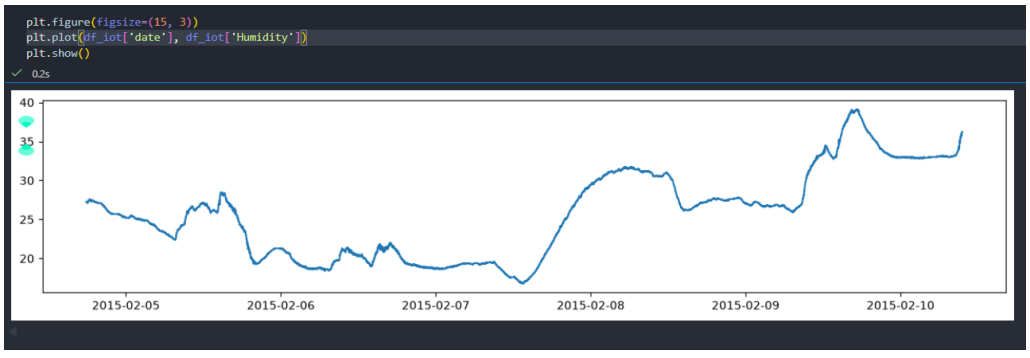
```
df_iot = pd.read_csv('https://raw.githubusercontent.com/ganjar87/data_science_practice/main/datatraining.txt')
df_iot['date'] = pd.to_datetime(df_iot['date'])
df_iot.head()
```

0.5s

	date	Temperature	Humidity	Light	CO2	HumidityRatio	Occupancy
1	2015-02-04 17:51:00	23.18	27.2720	426.0	721.25	0.004793	1
2	2015-02-04 17:51:59	23.15	27.2675	429.5	714.00	0.004783	1
3	2015-02-04 17:53:00	23.15	27.2450	426.0	713.50	0.004779	1
4	2015-02-04 17:54:00	23.15	27.2000	426.0	708.25	0.004772	1
5	2015-02-04 17:55:00	23.10	27.2000	426.0	704.50	0.004757	1

Gambar 4: Load dataset IoT

Selanjutnya, praktikan dapat membuat line chart dengan data yang ada pada dataset ioT untuk menampilkan perubahan nilai sensor terhadap waktu.



Gambar 5: Linechart dari data ioT

Kode tersebut digunakan untuk membuat grafik garis yang menampilkan hubungan antara tanggal dan tingkat kelembapan pada data IoT. Perintah `plt.figure(figsize=(15,`

3)) digunakan untuk mengatur ukuran grafik dengan lebar 15 dan tinggi 3. Selanjutnya, `plt.plot(df_iot['date'], df_iot['Humidity'])` digunakan untuk membuat grafik dengan kolom `date` sebagai sumbu x dan kolom `Humidity` sebagai sumbu y. Terakhir, `plt.show()` digunakan untuk menampilkan grafik yang telah dibuat.

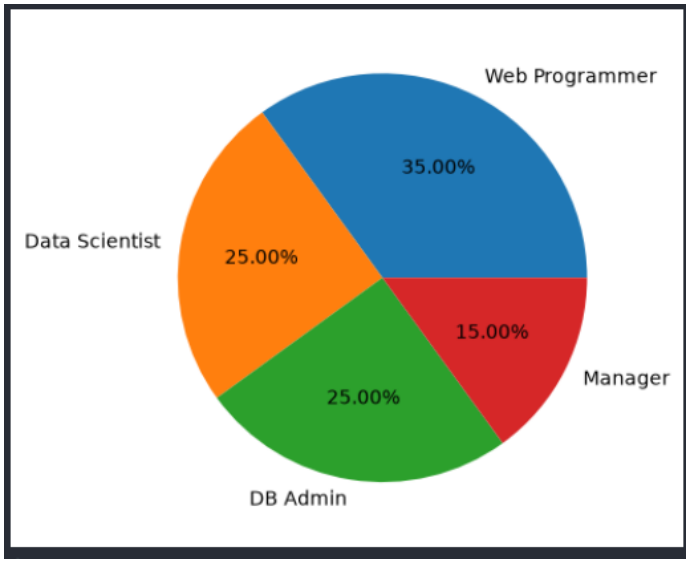
C.1.7 Pie Chart

Pie Chart digunakan untuk menampilkan proporsi dari setiap kategori dalam bentuk lingkaran. Setiap irisan pada lingkaran mewakili persentase dari kategori tersebut. Pie Chart sangat berguna untuk memahami distribusi data secara visual.

```
y = np.array([35, 25, 25, 15])
mylabels = ["Web Programmer", "Data Scientist", "DB
    Admin", "Manager"]

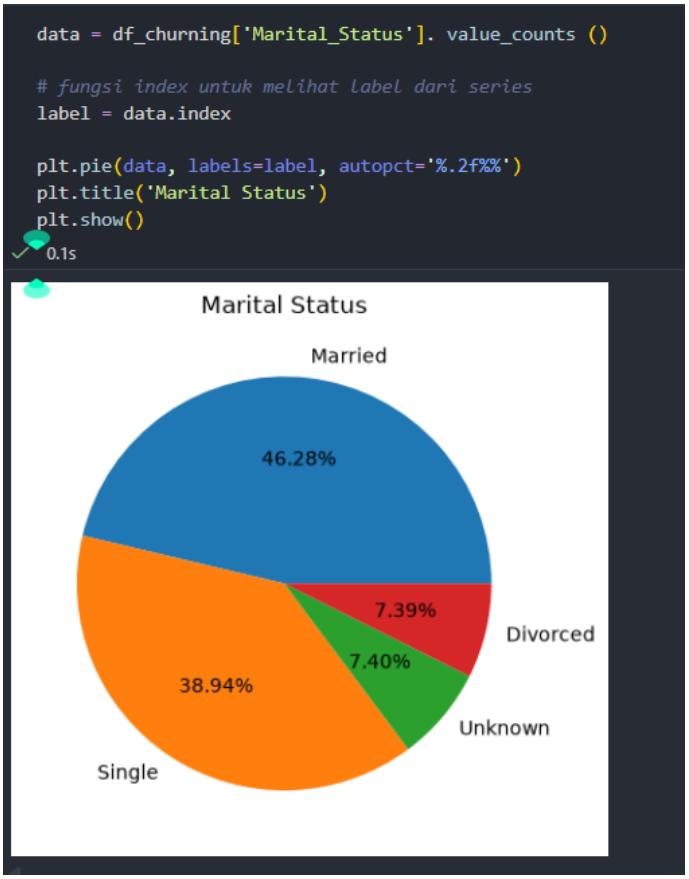
plt.pie(y, labels = mylabels, autopct='%.2f%%')
plt.show()
```

Kode tersebut digunakan untuk membuat *pie chart* yang menunjukkan persentase dari beberapa jenis pekerjaan. Variabel y berisi nilai data, sedangkan `mylabels` berisi label untuk setiap bagian, yaitu *Web Programmer*, *Data Scientist*, *DB Admin*, dan *Manager*. Perintah `plt.pie(y, labels=mylabels, autopct='%.2f%%')` digunakan untuk membuat diagram lingkaran dan menampilkan persentase setiap kategori dengan dua angka di belakang koma. Terakhir, `plt.show()` digunakan untuk menampilkan diagram seperti pada gambar 6.



Gambar 6: Pie Chart dari Data Pekerjaan

Selanjutnya, pembuatan pie chart dilakukan menggunakan dataset sebelumnya yaitu Bank Churner. Visualisasi ini bertujuan untuk menampilkan proporsi kategori pada variabel Marital_Status.



Gambar 7: Pie Chart dari Data Marital Status

Kode tersebut digunakan untuk membuat *pie chart* yang menampilkan distribusi status pernikahan dari data pelanggan. Perintah `df_churning['Marital_Status'].value_counts()` digunakan untuk menghitung jumlah data pada setiap kategori status pernikahan. Selanjutnya, `data.index` digunakan untuk mengambil label atau nama kategori dari *Series*. Perintah `plt.pie(data, labels=label, autopct='%.2f%')` digunakan untuk membuat diagram lingkaran dan menampilkan persentase setiap kategori dengan dua angka di belakang koma. Perintah `plt.title('Marital Status')` memberikan judul pada grafik, sedangkan `plt.show()` digunakan untuk menampilkan grafik.

C.1.8 Bar Plot

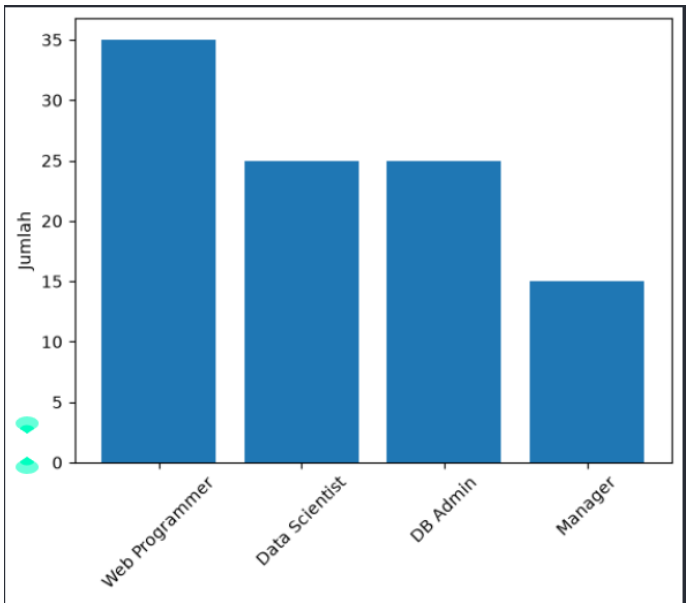
```
y = np.array([35, 25, 25, 15])
```

```
x = ["Web Programmer", "Data Scientist", "DB Admin",
    "Manager"]

plt.bar(x,y)

plt.xticks(rotation=45)
plt.ylabel('Jumlah')
plt.show()
```

Kode tersebut digunakan untuk membuat *bar chart* yang menampilkan jumlah pada setiap kategori pekerjaan. Variabel y berisi nilai jumlah, sedangkan x berisi nama kategori. Perintah `plt.bar(x,y)` membuat grafik batang, `plt.xticks(rotation=45)` memiringkan label sumbu x sebesar 45°, dan `plt.ylabel('Jumlah')` memberikan label pada sumbu y. Terakhir, `plt.show()` digunakan untuk menampilkan grafik seperti pada gambar 8.



Gambar 8: Bar Plot dari Data Pekerjaan

Selanjutnya, buat plot dengan dataset bank churner untuk membandingkan distribusi kategori marital_status antara 2 kelompok nasabah, yaitu existing customer

dan attrited customer. Visualisasi ini bertujuan untuk menampilkan perbandingan distribusi kategori pada variabel Marital_Status antara kedua kelompok nasabah.

```
y1 = existing_data['Marital_Status'].value_counts()
y2 = attrited_data['Marital_Status'].value_counts()

x1 = np.arange(len(y1.index))
x2 = np.arange(len(y2.index))
bar_width = 0.4

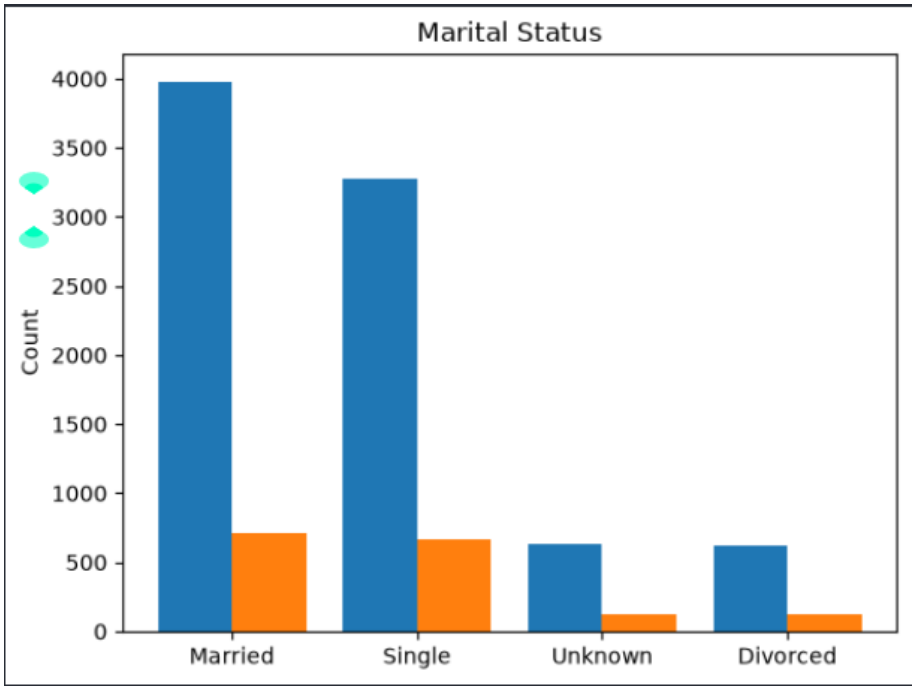
plt.bar(x1, y1, width=bar_width)
plt.bar(x2+bar_width, y2, width=bar_width)

plt.title('Marital Status')
plt.ylabel('Count')
plt.xticks(x2 + bar_width / 2, labels=df_churning.Marital_Status.unique())

plt.show()
✓ 0.2s
```

Gambar 9: Perbandingan Distribusi Marital Status

Kode tersebut digunakan untuk membuat *bar chart* yang membandingkan jumlah pelanggan berdasarkan status pernikahan pada dua kelompok data, yaitu *existing* dan *attrited*. Variabel y_1 dan y_2 digunakan untuk menghitung jumlah setiap kategori `Marital_Status`, sedangkan x_1 dan x_2 menentukan posisi batang pada sumbu x. Variabel `bar_width` mengatur lebar batang sebesar 0.4. Dua perintah `plt.bar()` digunakan untuk menampilkan kedua kelompok data secara berdampingan. Selanjutnya, `plt.title()` memberikan judul grafik, `plt.ylabel()` memberikan label sumbu y, dan `plt.xticks()` memberikan label kategori pada sumbu x. Terakhir, `plt.show()` digunakan untuk menampilkan grafik.



Gambar 10: Perbandingan Distribusi Marital Status

C.1.9 Stacked Bar Plot

C.1.10 Histogram

C.1.11 Scatter Plot

C.1.12 Box Plot

C.1.13 Violin Plot

C.1.14 Sub Plot

C.1.15 Annotation

C.1.16 Axis

C.1.17 Legend

C.2 Data Preprocessing

C.3 Tugas dan Analisis

D Kesimpulan

E Daftar Pustaka

[1] R. T. Team, "Artificial Intelligence: Pengertian, Sejarah, & Contohnya — ruangguru.com," https://www.ruangguru.com/blog/apa-itu-artificial-intelligence, 2025, [Accessed 28-08-2026].

[2] D. Intern, "Apa itu Machine Learning? Beserta Pengertian dan Cara Kerjanya - Dicoding Blog — dicoding.com," https://www.dicoding.com/blog/machine-learning-adalah/, 2020, [Accessed 28-08-2026].

[3] yunita ws, "MENGENAL EXPLORATORY DATA ANALYSIS – eksplorasidata.mipa.ugm.ac.id — eksplorasidata.mipa.ugm.ac.id," https://eksplorasidata.mipa.ugm.ac.id/2021/08/16/mengenal-exploratory-data-analysis/, 2021, [Accessed 28-08-2026].

[4] D. S. C. Team, "Data Preprocessing: Definisi, Tahapan, dan Implementasinya — digitalskola.com," https://digitalskola.com/blog/data-science/data-preprocessing, 2025, [Accessed 28-08-2026].